Correlación

Dr. Edgar Ramírez Galeano

Covarianza y Correlación

Cuando se estudian dos características, una pregunta que surge con frecuencia es si existe alguna relación entre ellas.

Como ejemplo podemos mencionar el peso y la estatura de un grupo de individuos, la temperatura y la taza de reproducción de una bacteria, el ingreso y el consumo por familias.

Propiedades de la Covarianza

La covarianza es una medida de asociación entre dos características que llamaremos X y Y.

$$S_{XY} = \frac{\sum(x_i - \bar{x})(y_i - \bar{y})}{n-1}$$

- Si S_{XY} es positivo, relación directa.
- Si S_{XY} es negativo, relación es indirecta.
- Si S_{XY} es cero, no existe relación entre las variables

Características de la Covarianza

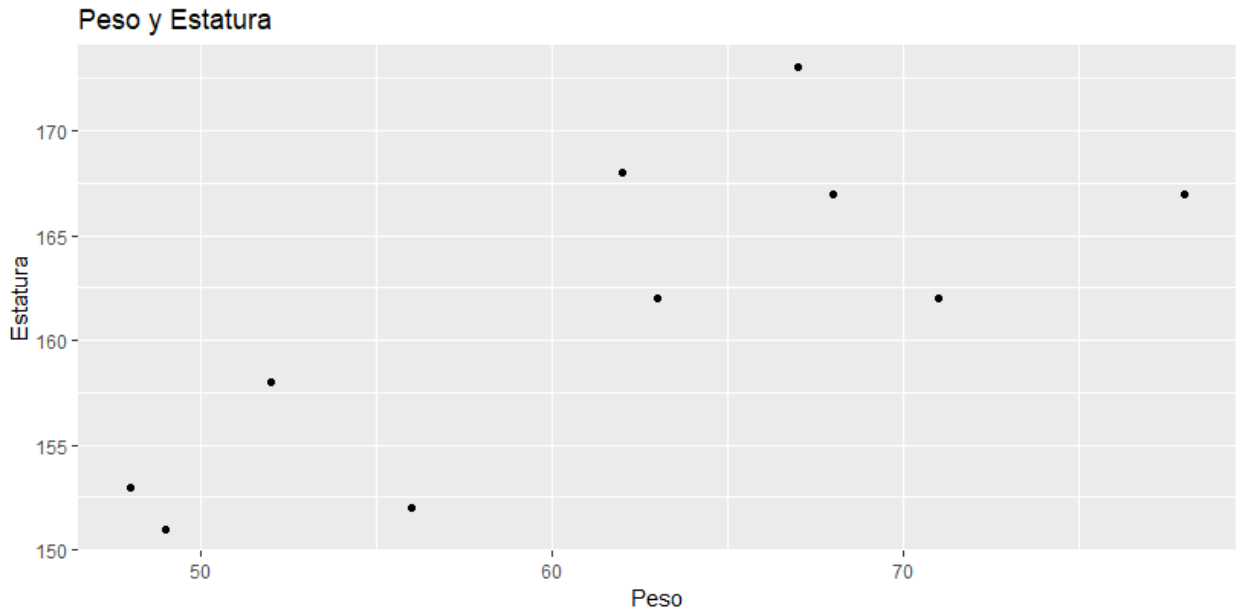
- **Mide la variación conjunta:** Indica cómo dos variables cambian juntas con respecto a sus medias.
- **Depende de la escala de las variables:** Su valor varía según las unidades de medida.
- **No implica causalidad:** Solo describe la relación entre variables, pero no indica si una causa cambios en la otra.
- **Sensibilidad a valores atípicos:** Puede verse afectada por la presencia de outliers.

Ejemplo de Covarianza

Peso	Estatura	Peso	Estatura
63	162	62	168
52	158	68	167
78	167	48	153
49	151	56	152
71	162	67	173

Table: Datos de Peso y Estatura

Ejemplo de Covarianza



x_i	y_i	$x_i - \bar{x}$	$y_i - \bar{y}$	$(x_i - \bar{x})(y_i - \bar{y})$
63	162	1.6	0.7	1.12
52	158	-9.4	-3.3	31.02
78	167	16.6	5.7	94.62
49	151	-12.4	-10.3	127.72
71	162	9.6	0.7	6.72
62	168	0.6	6.7	4.02
68	167	6.6	5.7	37.62
48	153	-13.4	-8.3	111.22
56	152	-5.4	-9.3	50.22
67	173	5.6	11.7	65.52
614	**1613**			**529.8**

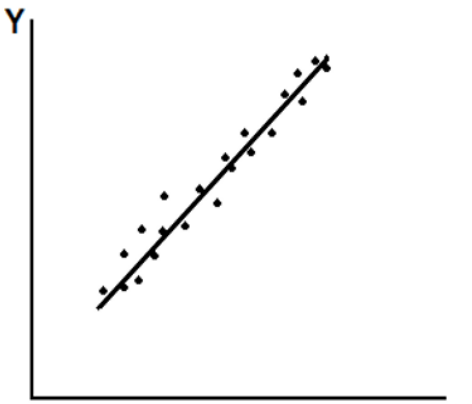
$$S_{XY} = \frac{1}{9}(529.80) = 58.86$$

Función en R

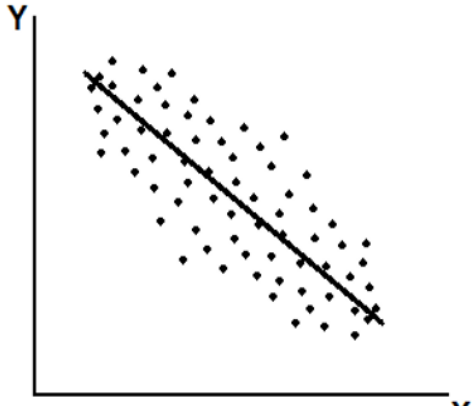
```
cov(PesoEstatura$Peso,PesoEstatura$Estatura)
```

CORRELACIÓN LINEAL

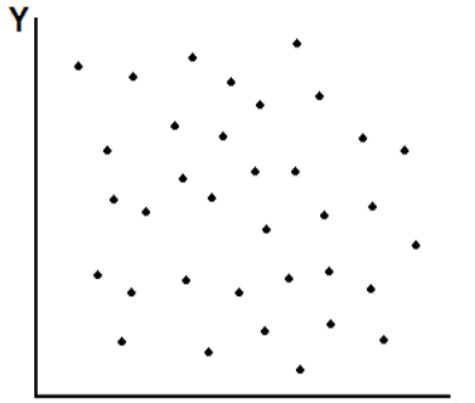
Si X e Y son las dos variables a considerar, un diagrama de dispersión muestra la ubicación de los puntos (X, Y) en un sistema de coordenadas rectangular. Si todos los puntos en este diagrama de dispersión se agrupan junto a una recta, como se observa en la Figura 1(a y b), la correlación se llama lineal.



a) Correlación lineal directa



b) Correlación lineal inversa



c) No hay correlación

Coeficiente de correlación de Pearson

Es una medida estandarizada ya que su valor está acotado en un rango fijo $[-1, 1]$, lo que permite comparar la fuerza y dirección de la relación entre variables sin depender de sus unidades de medida.

Se define como:

$$\rho = \frac{S_{XY}}{\sigma_X \sigma_Y}$$

Interpretación:

- $\rho = 1 \rightarrow$ Relación lineal positiva perfecta.
- $\rho = -1 \rightarrow$ Relación lineal negativa perfecta.
- $\rho = 0 \rightarrow$ No hay relación lineal.

Fuerza de la relación

Interpretación de la magnitud de ρ (Montgomery et al., 2012):

Valor de $\lvert\rho\rvert$	**Interpretación**
$0.00 - 0.20$	Correlación muy débil
$0.21 - 0.40$	Correlación débil
$0.41 - 0.60$	Correlación moderada
$0.61 - 0.80$	Correlación fuerte
$0.81 - 1.00$	Correlación muy fuerte

Nota: Un coeficiente alto no implica causalidad, solo una asociación lineal.

Fuente: Montgomery, D. C., Peck, E. A., & Vining, G. G. (2012). *Introduction to Linear Regression Analysis*. John Wiley & Sons.

Ejemplo de Correlación de Pearson

$S_{XY} = 58.56$
$S_X = 9.98$
$S_Y = 7.62$

$$\rho = \frac{58.56}{(9.98)(7.60)} = 0.7760$$

Función en R

```
cor(PesoEstatura$Peso,PesoEstatura$Estatura)
```

Correlación de Pearson

Es el método de correlación más utilizado pero asume que:

- La tendencia debe ser de tipo lineal.
- No existen valores atípicos (outliers).
- Las variables deben ser numéricas. Si las variables son de tipo ordinal no podremos aplicar la correlación de Pearson.

Los dos primeros supuestos se pueden evaluar simplemente con un diagrama de dispersión, mientras que para los últimos basta con mirar los datos y el diseño que tenemos.

Matriz de correlación

Disposición ordenada en una matriz de los coeficientes de correlación entre pares de variables de un conjunto, de forma que la posición de cada coeficiente de correlación viene dada por las variables que corresponden a la fila y columna correspondientes.

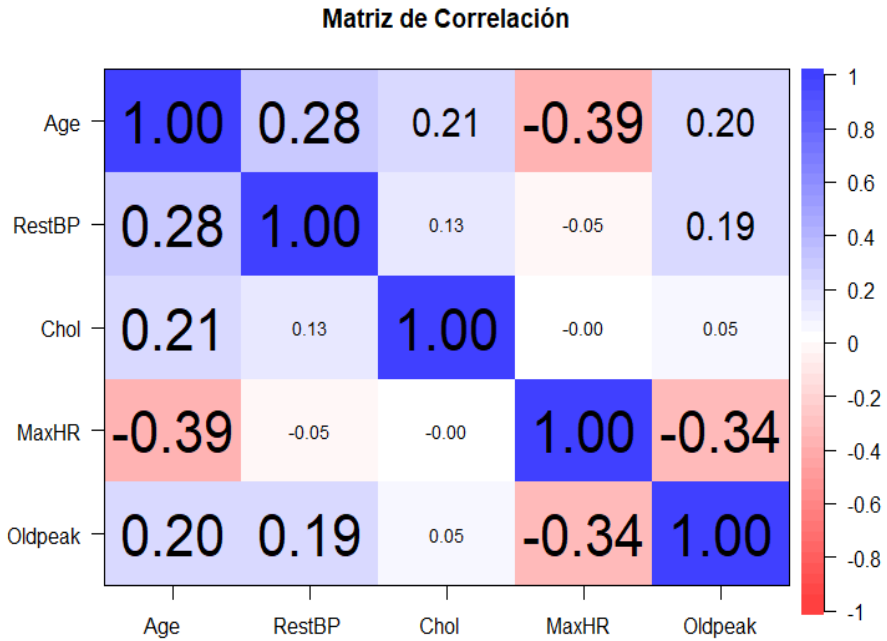
Ejemplo

```
HVarNum<-HEART %>%
select(Age:Oldpeak)
HVarNum <- as.matrix(HVarNum)
```

Matriz de correlación

```
> cor(HVarNum)
                Age      RestBP        Chol       MaxHR     Oldpeak
Age       1.0000000  0.28494592  0.208950270 -0.393805806  0.20380548
RestBP    0.2849459  1.00000000  0.130120108 -0.045350879  0.18917097
Chol      0.2089503  0.13012011  1.000000000 -0.003431832  0.04656399
MaxHR    -0.3938058 -0.04535088 -0.003431832  1.000000000 -0.34308539
Oldpeak   0.2038055  0.18917097  0.046563989 -0.343085392  1.00000000
```

Gráfica de la matriz de correlación

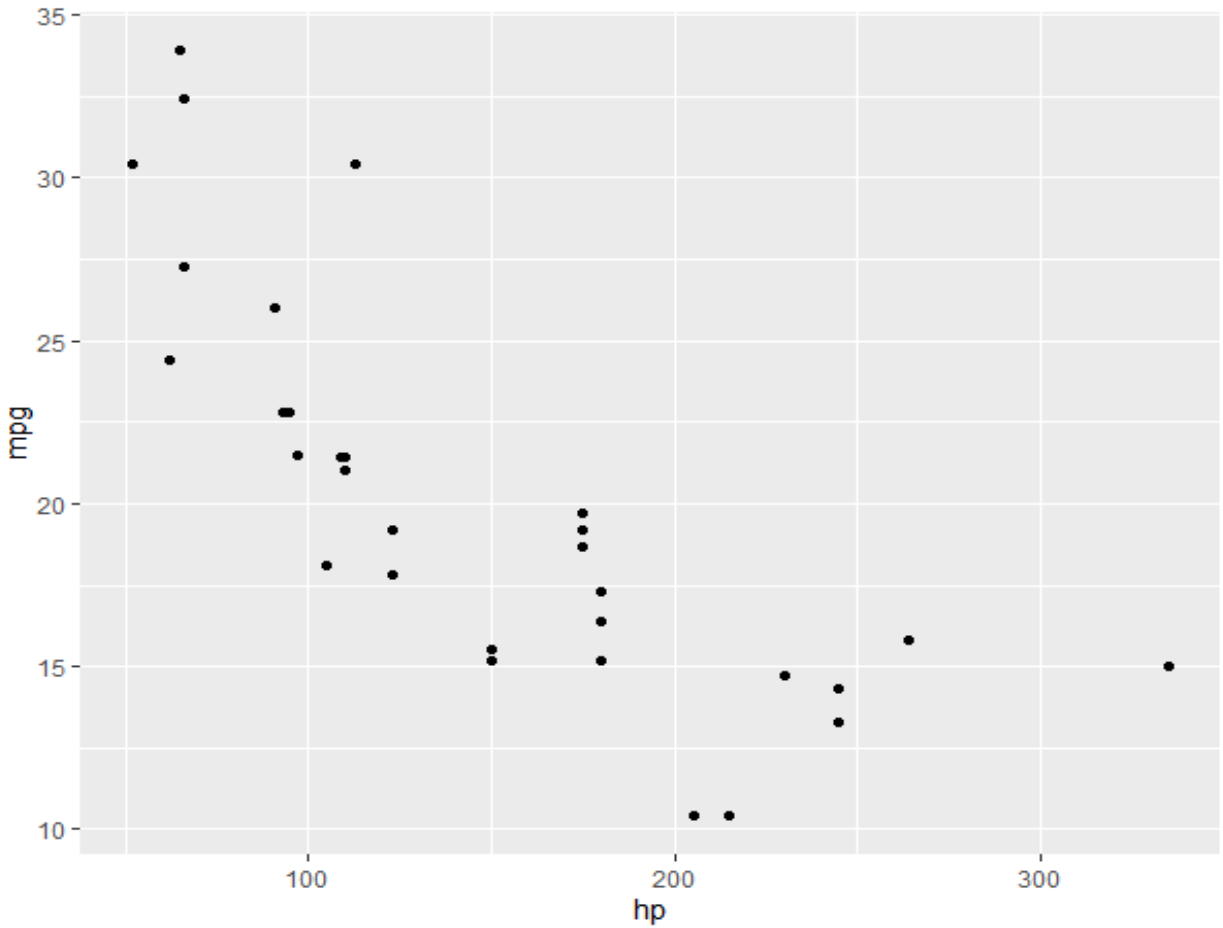



```
library(psych)
cor.plot(HVarNum,main="Matriz de Correlación")
```

Matriz de Varianza-Covarianza

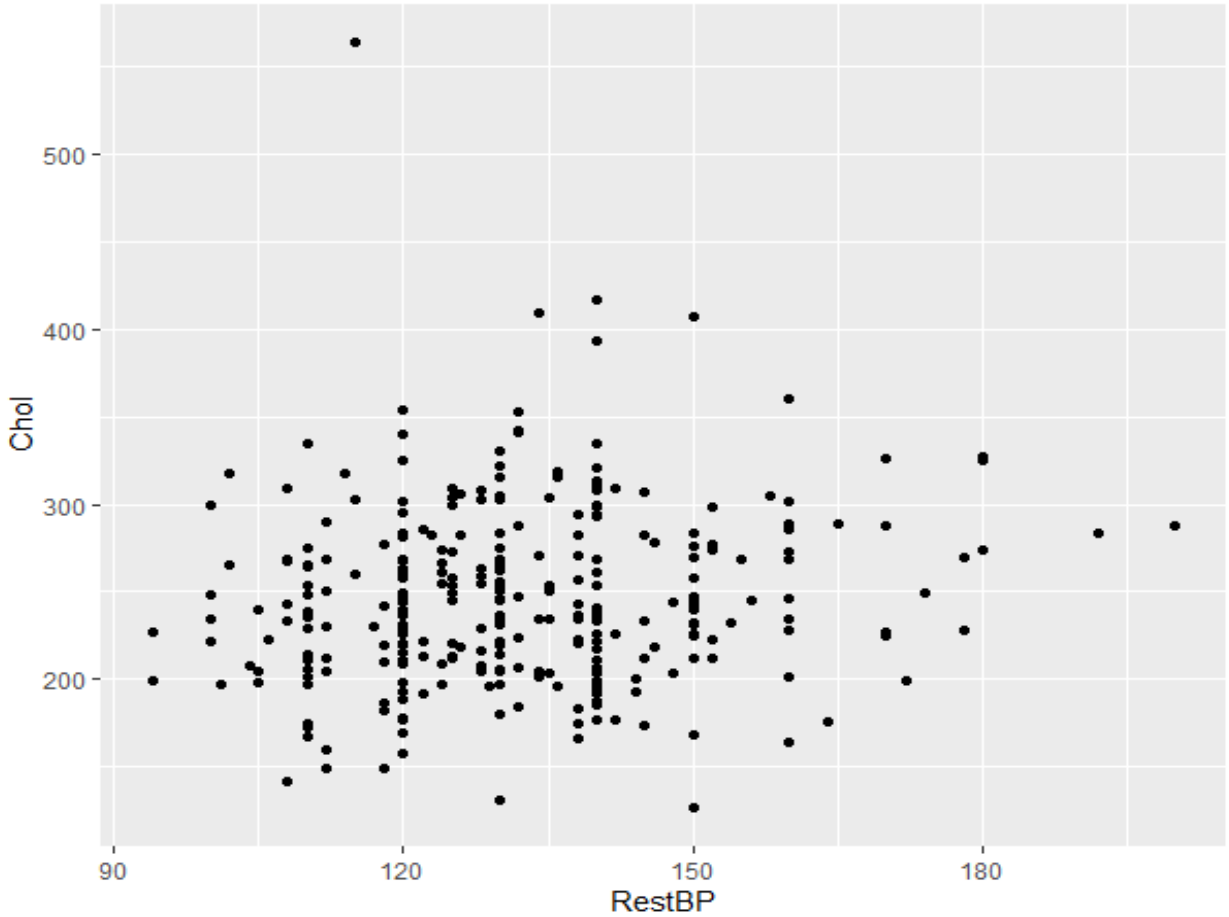
```
> var(HVarNum)
                Age     RestBP        Chol      MaxHR   Oldpeak
Age        81.69742  45.328678   97.787489 -81.423065  2.138850
RestBP     45.32868 309.751120  118.573339 -18.258005  3.865638
Chol       97.78749 118.573339 2680.849190  -4.064651  2.799282
MaxHR     -81.42307 -18.258005   -4.064651 523.265775 -9.112209
Oldpeak     2.13885   3.865638    2.799282  -9.112209  1.348095
```

Correlación negativa




```
cov(mtcars$mpg,mtcars$hp)
cor(mtcars$hp,mtcars$mpg)
```

Correlación Débil




```
cov(HEART$RestBP,HEART$Chol)
cor(HEART$RestBP,HEART$Chol)
```

Retos

Para los conjuntos de datos que se describen en cada uno de los retos deberá obtener la Covarianza y el Coeficiente de Correlación de Pearson.